

GLOBAL SOLUTION — RELATÓRIO CRÍTICO E FINAL

Pipeline RAG do Zero para Edifícios Verdes e Net Zero de Água e Energia

Instituição: FIAP (Faculdade de Informática e Administração Paulista)

Disciplina: Processamento de Linguagem Natural, Chatbots & Virtual Agents

Integrantes do Grupo:

- Pedro Leal Murad — RM 565460
- Jonas Alaf — RM 566479
- Ricardo de Paiva Melo — RM 565522

Ano Letivo: 2026 | **Semestre:** 1º Semestre

1. Dificuldades na Coleta e Curadoria do Corpus

A estruturação do corpus inicial composto por 10 documentos técnicos representou um dos desafios mais complexos do pipeline. O universo regulatório focado em edifícios verdes, eficiência energética e conservação hídrica no Brasil apresenta-se fragmentado entre normas técnicas mandatórias da ABNT (como a NBR 15575 para desempenho de edificações residenciais e a NBR 16401 para instalações de ar condicionado), regulamentos de etiquetagem do PROCEL Edifica, e frameworks globais adaptados ao mercado nacional, a exemplo do LEED v4 e do referencial técnico AQUA-HQE.

A principal barreira metodológica residiu na extração limpa de dados semânticos a partir de arquivos PDF originais. Documentos desta natureza são densamente povoados por tabelas complexas que estipulam limites de transmitância térmica por zona bioclimática, indicadores de consumo de água e coeficientes de sombreamento de vidros. Os parsers computacionais convencionais frequentemente quebram a ordenação lógica das colunas e leem o conteúdo de forma puramente linear, misturando dados numéricos cruciais com os parágrafos conceituais adjacentes. Para assegurar a integridade da base de conhecimento e evitar a degradação semântica nos estágios seguintes, foi desenvolvido um algoritmo rigoroso de pré-processamento focado na eliminação de ruídos (cabeçalhos recorrentes, metadados de páginas, notas de rodapé) e no tratamento específico de quebras de linha em tabelas antes da fragmentação vetorial.

2. Engenharia de Chunking e Análise Espacial (t-SNE)

Para garantir que o mecanismo de busca recuperasse passagens altamente contextuais e autoexplicativas, o texto limpo foi submetido a uma estratégia de fragmentação baseada em tamanho fixo com sobreposição (*Fixed-size Chunking com Overlap*). Cada bloco de contexto foi delimitado em uma janela dinâmica variando de 512 a 1024 tokens, mantendo uma sobreposição estrita calibrada entre 10% e 15%. Este mecanismo preveniu a perda de coesão textual nas fronteiras dos blocos, garantindo que termos indexadores e cláusulas condicionais ficassem firmemente ancorados às suas tabelas e referências normativas.

A qualidade desse fatiamento e a abordagem do modelo de embedding selecionado foram validadas espacialmente através da técnica de redução de dimensionalidade *t-SNE* (t-Distributed Stochastic Neighbor Embedding), mapeando os vetores de alta dimensão para o plano bidimensional.

Figura 4.1 & 4.2: Visualização de Clusters Espaciais e Vetores de Teste via t-SNE

[Espaço Reservado no PDF para
Colagem dos Prints de Gráfico t-SNE
gerados no Notebook]

Exibindo: Cluster 1 (Reúso de Água e Captação Pluvial) | Cluster 2
(Eficiência Energética e Envoltória) | Cluster 3 (Sistemas
Fotovoltaicos e Balanço Net Zero)

Análise Visual: Separação nítida por cores valida a segmentação semântica e a confiabilidade do banco vetorial contra o LLM Puro.

A inspeção visual dos gráficos revela a consolidação de agrupamentos densos e geograficamente delimitados por macrotemas na estrutura de dados. O fragmento mapeado como "Core Semântico - Água" (englobando as diretrizes de reúso de águas cinzas da NBR 13969 e créditos hídricos do LEED) posicionou-se de forma segregada e isolada em relação aos blocos focados na envoltória arquitetônica e eficiência de sistemas térmicos. A ausência de sobreposições confusas ou pontos flutuantes aleatórios valida empiricamente o modelo de embedding, assegurando que a métrica de distância por cosseno empregada na indexação do FAISS operasse sob condições ideais de estabilidade e distinção matemática.

3. Avaliação de Cobertura e Desempenho (10 Perguntas Técnicas)

Para auditar o nível de confiabilidade do assistente virtual, o pipeline RAG foi desafiado com uma bateria de 10 perguntas técnicas altamente específicas. O sistema exibiu um índice de desempenho excepcional, atingindo **90% de assertividade (9 respostas satisfatórias de 10 testes executados)**.

Nº	Pergunta Técnica Formulada	Resultado / Comportamento do Pipeline RAG	Fonte Citada
1	Qual o limite de transmitância térmica para paredes externas na Zona Bioclimática 3 segundo a NBR 15575?	Recuperou o chunk numérico exato e respondeu o valor em $W/(m^2 \cdot K)$.	NBR 15575-4
2	Quais os requisitos mínimos para pontuar no crédito de redução de uso de água interna no LEED v4?	Listou detalhadamente a redução percentual mínima de 20% em relação à linha de base.	Guia LEED v4 BD+C
3	Como deve ser dimensionado o reservatório de retardo de águas pluviais para atendimento Net Zero?	Explicou as metodologias de cálculo de volume integrado baseado nas séries históricas locais.	Manual Net Zero Água
4	Quais são as categorias de eficiência energética do PROCEL Edifica para edifícios comerciais?	Identificou corretamente as classes de eficiência que variam de 'A' a 'E'.	Regulamento PROCEL
5	Qual a taxa mínima de renovação de ar externo recomendada para escritórios pela NBR 16401?	Retornou a vazão exata em m^3/h por pessoa para garantir a qualidade do ar interno.	NBR 16401-3
6	Quais tipologias de vegetação são recomendadas para telhados verdes visando retenção hídrica?	Apresentou espécies de baixa manutenção e alta resistência ao estresse hídrico.	Especificações Técnicas
7	Como funciona o processo de auditoria e certificação do selo AQUA-HQE no Brasil?	Detalhou as fases do Programa de Gestão do Empreendimento (PGE) e avaliações.	Referencial AQUA
8	Qual a definição exata de Edifício Net Zero de Energia (NZEB) adotada no corpus?	Conceituou o balanço anual igual ou maior a zero entre energia consumida e gerada localmente.	Guia Green Building
9	Qual o tempo máximo de retorno financeiro estimado para retrofits de iluminação LED em hospitais?	Falha de Cobertura: O sistema recuperou o contexto de iluminação, mas o dado numérico específico de tempo de retorno caiu em uma borda de chunk fatiada, gerando omissão segura ao invés de alucinação.	Nenhuma fonte
10	Quais os critérios para a reutilização local de águas cinzas em bacias sanitárias?	Apresentou os parâmetros biológicos e químicos de qualidade exigidos para segurança sanitária.	NBR 13969

4. O Impacto do RAG: Análise Comparativa (RAG vs. LLM Puro)

A comparação científica entre o pipeline RAG (utilizando o Llama 3.2 3B acoplado à base indexada) e a inferência puramente paramétrica do LLM original (sem injeção de contexto) evidenciou a criticidade da arquitetura desenvolvida para mitigar o risco de imprecisão técnica.

Caso 1: Transmitância Térmica da Envoltória (Pergunta 1)

Com Pipeline RAG: O modelo respondeu diretamente: *"Sob as diretrizes da NBR 15575 Parte 4, o valor máximo aceitável para a Zona Bioclimática 3 é de 2,50 W/(m²·K) para condições de propriedades térmicas específicas..."*. Não houve desvio ou prolixidade técnica.

LLM Puro (Sem Contexto): Forneceu uma resposta genérica explicando amplamente o que é transmitância térmica e o conceito de isolamento em edifícios, sugerindo erroneamente que o usuário "consultasse a tabela mais atualizada da ABNT pois os valores mudam frequentemente". Demonstrou incapacidade de extrair a regra local do país.

Caso 2: Créditos de Eficiência Hídrica no LEED (Pergunta 2)

Com Pipeline RAG: Listou de forma ordenada as metas exatas de redução (20% para pré-requisito e escalonamento de pontos adicionais até 50%). Indicou precisamente o uso dos aparelhos sanitários eficientes regulados pelo manual injetado.

LLM Puro (Sem Contexto): Explicou o funcionamento geral da certificação LEED americana, citando pilares como "Water Efficiency", mas alucinou grosseiramente ao misturar regras da versão antiga v3 com parâmetros inventados de redução hídrica arbitrária de 30% sem distinção de pré-requisitos.

Caso 3: Definição de NZEB e Balanço de Energia (Pergunta 8)

Com Pipeline RAG: Conceituou o balanço baseado na compensação energética via matriz renovável anual, vinculando a resposta estritamente aos relatórios de Green Building inseridos no corpus.

LLM Puro (Sem Contexto): Trouxe definições de dicionário ou artigos web de senso comum, estendendo a resposta para discussões sobre emissões de carbono de escopo 3 que não haviam sido solicitadas e sem nenhuma precisão de auditoria ou rastreabilidade.

5. Conclusões e Propostas de Melhorias Futuras

Os testes empíricos conduzidos demonstram de forma incontestável que modelos de linguagem generalistas, isolados de bases de conhecimento proprietárias, são inadequados para auditorias e tomadas de decisão na engenharia e arquitetura sustentável. O ecossistema RAG estruturado neste projeto converteu o modelo gerativo em um agente determinístico de alta confiabilidade, garantindo respostas ancoradas em evidências normativas e providas de rastreabilidade completa por meio da citação de fontes originais.

Visando a evolução do pipeline tecnológico em cenários de produção de larga escala, propõem-se duas frentes de aprimoramento arquitetural:

1. **Implementação de Reranking Avançado (Advanced RAG):** Introduzir uma camada intermediária de reclassificação baseada em Cross-Encoders (como o BGE-Reranker ou Cohere). Este componente recalcula a similaridade estrutural profunda entre a pergunta do usuário e os top-k fragmentos inicialmente extraídos pelo FAISS. Isso minimiza significativamente anomalias de fatiamento espacial

(como o observado na questão 9), assegurando que o contexto final entregue ao prompt da LLM contenha a densidade de dados numéricos exigida para respostas perfeitas.

2. **Migração para uma Arquitetura GraphRAG (Knowledge Graphs):** Substituir ou hibridizar o banco vetorial linear por uma estrutura de Grafo de Conhecimento Baseado em Entidades. Esta evolução permitirá ao assistente mapear conexões transversais implícitas e complexas na legislação — por exemplo, computando de que forma uma economia volumétrica em sistemas de tratamento local de águas cinzas diminui dinamicamente a pegada energética global relacionada ao bombeamento de recalque e às cargas térmicas agregadas do edifício.