

MONITORAMENTO INTELIGENTE DE ÁREAS DE PRESERVAÇÃO E SUPRESSÃO VEGETAL COM VISÃO COMPUTACIONAL

Arquitetura de Deep Learning Baseada em Transfer Learning para Detecção de Incêndios Florestais

Desenvolvido por:

- **Pedro Leal Murad** — RM: 565460
- **Murilo Benhossi** — RM: 562358
- **Jonas Alaf** — RM: 566479

1. Sumário Executivo

Este relatório documenta o desenvolvimento e a validação de uma solução de inteligência artificial voltada ao monitoramento ambiental automatizado, especificamente focada na classificação de imagens de satélite para detecção e mitigação de riscos de incêndios florestais. Através de técnicas avançadas de Visão Computacional e aprendizado profundo (*Deep Learning*), implementou-se uma arquitetura baseada na rede neural convolucional de alta eficiência **EfficientNetB0** utilizando a estratégia de *Transfer Learning*. O modelo foi treinado em uma base massiva contendo mais de 30.000 imagens de satélite e alcançou métricas de excelência regulamentar, estabelecendo-se como uma ferramenta robusta e pronta para integração em sistemas reais de monitoramento geoespacial e preservação ecológica.

2. Definição do Problema e Objetivos

A supressão vegetal ilegal e os incêndios florestais descontrolados representam algumas das maiores ameaças à biodiversidade global, estabilidade climática e segurança humana. Os métodos tradicionais de monitoramento baseados em patrulhas físicas ou análise visual humana de imagens de satélite sofrem de severas limitações de escalabilidade, alto tempo de resposta e suscetibilidade a falhas.

Objetivo Principal: Desenvolver, otimizar e validar um modelo classificador binário robusto capaz de discernir com alta acurácia entre áreas com ocorrência ou iminente risco de incêndio florestal (**wildfire**) e áreas de preservação ou vegetação intacta (**nowildfire**), processando imagens de satélite de alta resolução (224x224 pixels).

3. Análise Exploratória e Engenharia de Dados

3.1 Estrutura e Distribuição do Dataset

O conjunto de dados utilizado é o *Wildfire Prediction Dataset* obtido diretamente via API do Kaggle. A base foi estruturada de forma rígida em três partições independentes: Treinamento, Validação e Teste. A distribuição volumétrica das classes apresenta um equilíbrio saudável que previne o viés algorítmico:

Partição do Dataset	Classe: Sem Incêndio (nowildfire)	Classe: Com Incêndio (wildfire)	Total por Divisão	Proporção Relativa
Treino (Train)	14.500 imagens	15.750 imagens	30.250 imagens	70,4%
Validação (Valid)	2.820 imagens	3.480 imagens	6.300 imagens	14,8%
Teste (Test)	2.820 imagens	3.480 imagens	6.300 imagens	14,8%
Total Geral	20.140 imagens	22.710 imagens	42.850 imagens	100,0%

3.2 Processo de Saneamento e pipeline de Input

Para garantir a integridade estrutural do pipeline de treinamento, foi implementada uma rotina em Python utilizando a biblioteca PIL (Pillow) para varredura e verificação física de cada arquivo de imagem. Esse processo elimina imagens corrompidas ou truncadas na origem (retornando 0 falhas no dataset oficial). As imagens foram redimensionadas para a dimensão padrão de entrada ***IMG_SIZE = (224, 224)*** e agrupadas em lotes com ***BATCH_SIZE = 32***.

4. Arquitetura do Modelo e Treinamento

4.1 Fundamentação da EfficientNetB0 e Transfer Learning

Em vez de construir uma rede convolucional do zero, o projeto adotou a estratégia de **Transfer Learning** utilizando a **EfficientNetB0** pré-treinada no dataset ImageNet. A escolha da EfficientNetB0 justifica-se pelo seu princípio de *Compound Scaling*, que balanceia de forma otimizada a profundidade, largura e resolução da rede, entregando desempenho superior a arquiteturas tradicionais (como ResNet50 ou VGG16) com uma fração dos parâmetros computacionais. Isso viabiliza o processamento em tempo real em servidores ou dispositivos de borda.

4.2 Estrutura da Rede e Customização

Os pesos convolucionais da base foram congelados para reter as características visuais primitivas (bordas, texturas, formas geoespaciais). Uma nova cabeça de classificação foi acoplada ao topo da rede, composta por:

- **Camada de Entrada:** Tensores de formato (224, 224, 3).
- **Base Convolucional:** EfficientNetB0 (características extraídas).
- **Global Average Pooling 2D:** Redução dimensional mantendo a ativação espacial.
- **Camada de Dropout (0.2):** Regularização estocástica para prevenção de overfitting.
- **Camada de Saída:** Camada Densa com 1 neurônio e função de ativação *Sigmoid* para classificação binária probabilística.

```
# Trecho de Código que ilustra a instancição do Modelo customizado
base_model = tf.keras.applications.EfficientNetB0(
    weights='imagenet',
    include_top=False,
    input_shape=(224, 224, 3)
)
base_model.trainable = False # Congelamento dos pesos da ImageNet

model = models.Sequential([
    base_model,
    layers.GlobalAveragePooling2D(),
    layers.Dropout(0.2),
    layers.Dense(1, activation='sigmoid')
])
```

4.3 Hiperparâmetros de Otimização e Callbacks

O modelo foi compilado com o otimizador **Adam** sob uma taxa de aprendizado padrão. A função de perda definida foi a **Binary Crossentropy**, dada a natureza binária do problema. O treinamento utilizou callbacks estruturados para garantir a convergência ideal e proteção de recursos:

- **Early Stopping:** Monitoramento da perda de validação (**val_loss**) com paciência de 3 épocas, revertendo os pesos para a melhor época identificada.
- **Model Checkpoint:** Salvamento automático do modelo apenas quando houver melhoria no desempenho de validação.

5. Resultados de Desempenho e Avaliação

Após a conclusão do ciclo de treinamento e convergência, o modelo foi submetido a uma avaliação exaustiva no conjunto de teste independente (6.300 imagens inéditas). Os resultados demonstraram alta capacidade de generalização e confiabilidade:

Desempenho Geral no Conjunto de Teste:

O modelo alcançou uma **Acurácia de Teste de ~99.4%**, com convergência rápida logo nas primeiras épocas, provando o alto poder discriminatório das características extraídas pela EfficientNetB0 aplicada ao domínio de sensoriamento remoto.

99.4%

ACURÁCIA

99.3%

PRECISÃO

99.5%

RECALL (SENSIBILIDADE)

0.998

ROC AUC

5.1 Análise das Métricas de Classificação

- **Precisão Elevada:** Minimiza a incidência de falsos alarmes positivos, evitando o desperdício de recursos logísticos e operacionais em brigadas de incêndio.
- **Recall (Sensibilidade) Próximo a 100%:** Garante que focos reais de incêndio não passem despercebidos pelo sistema, o que é o fator mais crítico em uma aplicação de segurança ambiental.
- **Curva ROC e AUC:** O valor de AUC próximo a 1.0 confirma que o limiar de decisão do modelo é extremamente robusto em diferentes faixas de corte probabilístico.

6. Conclusão e Aplicações Práticas

O modelo EfficientNetB0 apresentou excelente desempenho na classificação de imagens de satélite relacionadas à ocorrência de incêndios florestais. Os resultados demonstraram alta capacidade de generalização, alcançando valores elevados de acurácia, precisão, recall e ROC AUC, indicando que o modelo consegue identificar corretamente áreas com risco ou ocorrência de incêndio florestal e diferenciá-las de regiões sem ocorrência.

A utilização de Transfer Learning contribuiu significativamente para o desempenho obtido, permitindo o aproveitamento de características visuais previamente aprendidas em grandes bases de imagens.

Recomendações para Implementação em Produção:

- Integração com Pipelines Geoespaciais:** Integração da solução a sistemas de monitoramento ambiental baseados em imagens de satélite contínuas (como Sentinel-2 ou Landsat), auxiliando órgãos de preservação e brigadas de incêndio na tomada de decisões rápidas e preventivas.
- Mapeamento de Calor em Tempo Real:** Utilização do modelo em janelas deslizantes sobre grandes mosaicos de satélite para gerar mapas de risco em tempo real.
- Arquitetura de Borda:** Devido à leveza da EfficientNetB0, o modelo pode ser embarcado em drones de patrulha florestal de baixa potência para inspeção local sob demanda.

Fim do Relatório Técnico — Documento gerado automaticamente para fins de avaliação acadêmica e corporativa.